

Predictia pretului smartphone-urilor de pe platforma Emag

1. Introducere

Piața de e-commerce pentru dispozitive mobile este caracterizată de o diversitate foarte mare de produse, diferențiate atât prin specificații tehnice, cât și prin brand. Pentru utilizatori, dar și pentru comercianți, estimarea unui preț corect al unui telefon mobil reprezintă o problemă relevantă, cu aplicații practice precum compararea produselor, identificarea ofertelor avantajoase sau analiza competitivității.

Scopul acestui proiect este de a construi un sistem de predicție a prețului telefoanelor mobile pe baza caracteristicilor tehnice și a informațiilor disponibile public pe Emag (și nu numai). Obiectivele principale ale proiectului sunt:

- colectarea automată a datelor despre telefoane mobile prin web scraping;
- preprocesarea și curățarea datasetului;
- analiza exploratorie a datelor (EDA);
- antrenarea și evaluarea mai multor modele de regresie;
- analiza erorilor și interpretabilitatea modelelor.

2. Colectarea și preprocesarea datelor

Datele au fost colectate de pe platforma eMAG, folosind tehnici de web scraping. Pentru fiecare telefon mobil au fost extrase informații precum:

- prețul produsului;
- brandul;
- capacitatea de stocare;
- memoria RAM;
- dimensiunea ecranului;
- rezoluția camerei (megapixeli);
- alte specificații disponibile public.

În etapa de preprocesare au fost realizate următoarele operații:


- eliminarea sau completarea valorilor lipsă;
- conversia caracteristicilor numerice (ex. „128 GB”) în valori numerice;
- normalizarea unor variabile (ex. `storage_norm`, `megapixels_norm`) pentru a permite comparații coerente;
- codificarea variabilelor categorice folosind one-hot encoding (ex. brandul).

3. Exploratory Data Analysis (EDA)

Analiza exploratorie a datelor a avut ca scop înțelegerea distribuțiilor, relațiilor dintre variabile și identificarea unor tipare relevante.


3.1 Distribuția prețurilor

- Distribuția prețurilor telefoanelor este puternic asimetrică pozitiv, cu majoritatea valorilor concentrate sub 3000 lei și o coadă lungă spre prețuri foarte mari (peste 10 000 lei), ceea ce indică existența unor modele premium rare.




3.2 Corelații între caracteristici:

- Matricea de corelație arată că prețul este moderat corelat cu memoria internă (0.53), RAM-ul (0.52) și numărul de megapixeli (0.66).
- Corelația dintre preț și dimensiunea ecranului este mai slabă (0.30).
- Se observă o corelație puternică între RAM și storage (0.65).
- Corelația preț–RAM evidențiază o tendință ascendentă, telefoanele cu mai mult RAM având, în general, prețuri mai mari.




3.3 Analiza relațiilor dintre preț și alte caracteristici:

- Graficul preț–RAM indică o relație pozitivă clară, telefoanele cu mai mult RAM având, în general, prețuri mai ridicate.
- În cazul preț–storage, se observă o tendință ascendentă moderată..
- Graficele evidențiază prezența unor valori extreme, corespunzătoare modelelor premium.
- Relația dintre preț și rezoluția ecranului (megapixeli) este vizibil pozitivă.
- Pentru valori mici ale specificațiilor, prețurile sunt concentrate într-un interval redus.
- În concluzie, prețul crește odată cu performanța hardware, însă variația ridicată arată că brandul și alte specificații joacă un rol important



3.4 Analiza pretului mediu pe brand

- Diferențe semnificative între prețurile medii ale telefoanelor în funcție de brand.
- Brandurile din zona inferioară a graficului oferă prețuri medii reduse.
- În zona mediană se află branduri cu prețuri moderate.
- Brandurile din partea superioară prezintă cele mai mari prețuri medii.
- Segmentare clară a pieței.



4. Modele de Machine Learning

4.1 Modele utilizate

Pentru predicția prețului au fost antrenate și comparate următoarele modele:

- **Linear Regression** – utilizat ca model de bază (baseline);
- **Random Forest Regressor** – model ensemble bazat pe arbori de decizie;
- **Gradient Boosting Regressor** – model ensemble bazat pe boosting.

Modelele bazate pe arbori au fost alese datorită capacității lor de a surprinde relații non-liniare și interacțiuni complexe între variabile.

4.2 Setare experimentală

Datasetul a fost împărțit într-un set de antrenare (80%) și un set de test (20%). Performanța modelelor a fost evaluată folosind următoarele metrici:

- Mean Absolute Error (MAE);
- Root Mean Squared Error (RMSE);
- Coefficient of Determination (R^2).

Pentru Random Forest au fost testate atât variante ne-regularizate, cât și variante cu parametri de regularizare (`max_depth`, `min_samples_leaf`) pentru a reduce overfitting-ul.


5. Rezultate și comparație modele

Rezultatele obținute indică o performanță ridicată pentru modelele ensemble. Random Forest și Gradient Boosting au obținut valori R^2 ridicate, semnificativ mai bune decât modelul de regresie liniară.


Comparativ:

- regresia liniară nu reușește să surprindă relațiile complexe dintre variabile;
- Random Forest oferă cea mai bună performanță generală;
- Gradient Boosting oferă rezultate comparabile, dar cu o sensibilitate mai mare la parametri.


Graficul „preț real vs. preț prezis” pentru cel mai bun model arată o bună aliniere a predicțiilor cu valorile reale, confirmând capacitatea modelului de a generaliza.



```
--- Random Forest ---  
MAE: 453.002443837688  
RMSE: 786.113316822382  
R2 train: 0.9562887641437814  
R2 test: 0.7894036093110319
```



```
--- Gradient Boosting ---  
MAE: 514.6063687233061  
RMSE: 848.5951144740163  
R2 train: 0.9401936137712089  
R2 test: 0.7545959807606551
```



```
--- Linear Regression ---  
MAE: 818.679246001484  
RMSE: 1057.8471204956497  
R2 train: 0.6047845545958592  
R2 test: 0.6186476442223399
```

=== Comparatie modele ===

	Model	MAE	RMSE	R ²
0	Random Forest	453.002444	786.113317	0.789404
3	HistGradient Boosting	503.517807	842.690985	0.757999
1	Gradient Boosting	514.606369	848.595114	0.754596
2	Linear Regression	818.679246	1057.847120	0.618648

6. Analiza erorilor și interpretabilitate

Analiza erorilor a evidențiat existența unor telefoane considerate subevaluate sau supraevaluate de model. Aceste diferențe pot fi explicate prin:

- factori neobservați în date;
- strategii comerciale ale brandurilor;
- promoții sau reduceri temporare.

Analiza importanței variabilelor a arătat că anumite caracteristici (de exemplu, scoruri derivate din preț) pot deveni dominante și pot induce bias. De asemenea, brandul, deși codificat binar, poate deveni un feature important datorită asocierii sale consistente cu anumite niveluri de preț.

Eliminarea variabilelor care conțin informație implicită despre preț a fost esențială pentru evitarea overfitting-ului și pentru obținerea unui model interpretabil.

7. Concluzii

Analiza realizată arată că **prețul telefoanelor mobile poate fi prezis cu o acuratețe ridicată** atunci când sunt utilizate modele de machine learning neliniare.

Modelul **Random Forest**, ales ca model final, reușește să explice aproximativ **79% din variația prețurilor** pe date nevăzute ($R^2 \text{ test} \approx 0.79$), cu o eroare medie de aproximativ **450 unități monetare**. Acest lucru indică faptul că predicțiile sunt **fiabile și utile în practică**.

Rezultatele sugerează că:

- caracteristicile tehnice (performanță, specificații, brand etc.) influențează semnificativ prețul;
- relația dintre caracteristici și preț este **complexă**, motiv pentru care modelele simple nu sunt suficiente;
- modelul poate fi folosit pentru:
 - **estimarea prețului corect** al unui telefon nou,
 - **detectarea telefoanelor subevaluate și supraevaluate**,

- **sprijinirea deciziilor comerciale** (pricing, recomandări).

Predicția prețurilor telefoanelor este realizabilă și relevantă, iar utilizarea Random Forest oferă un instrument eficient pentru evaluarea valorii reale a unui telefon pe piață.

Ca direcții viitoare de dezvoltare pot fi avute în vedere:

- integrarea evoluției temporale a prețurilor;
- utilizarea mai multor surse de date;
- aplicarea tehnicilor NLP pe descrierile produselor;
- testarea unor modele mai avansate sau a validării cross-validation.